第十一届全国大学生生物医学工程创新设计竞赛

预赛作品报告

基于智能手表传感器的进食检测算法

作品 ID 号：5630

参赛学生类型：本科生

参加赛道：智能穿戴与运动健康赛道

组别：命题项目组（赛题二）

2026 年 9 月

请勿在作品中出现参赛者及指导教师相关学校及个人信息，否则不予评审

内容完整性自查表

完整性类别	任务或技术指标名称	完成效果	呈现方式
赛题任务	惯用手佩戴场景	检出52/63，召回率0.8254	第10页，表2
赛题任务	非惯用手佩戴场景	检出62/90，召回率0.6889	第10页，表2
主要指标	事件级全局F1	官方反馈最佳F1为0.533333	第10页，表3
次要指标	匹配事件起止时间MAE	起始323.43秒，终止116.87秒；本地114个匹配事件	第10页
研究过程	方案设计与实验分析	轻量化基线、两级检测、评测修正及后续改进探索	第5—9页
交付物	Windows可执行程序	模型和运行依赖内置，无需预装Python或联网	第11页
交付物	模型源码与复现说明	包含训练、评估、构建代码及正式模型证据	第10—11页
交付物	总结报告及可视化	本报告；离线事件分析与腕部姿态回放	第11—12页

说明：场景及边界指标来自153个可评估事件的历史本地评估；官方反馈以112个有效真实事件为分母，两者口径不同，不能直接比较。

摘 要

针对自由生活环境下进食动作与日常手部活动易混淆的问题，构建面向两类佩戴场景的双尺度事件检测方法。系统从智能手表原始惯性数据恢复时间轴，以240秒宏窗和15秒微窗产生候选，再通过候选控制与116维事件表示进行逻辑回归、LightGBM融合复核。历史受试者隔离嵌套五折以153个可评估事件为分母，聚合F1为0.6514。后续开展外部手势迁移、TCN、Transformer、PPG及事件均衡损失研究，局部增益未稳定复现。官方反馈三次F1分别为0.466667、0.521277和0.533333，均为112个有效真实事件，最终程序固定最佳反馈配置。本地结果与官方结果评价范围不同。工程交付包含内置模型与依赖的Windows程序、训练源码和离线可视化应用。

关键词：进食检测，智能手表，惯性传感器，事件复核，嵌套交叉验证

目 录

摘要 3

1 作品概述 5

1.1 背景及意义 5

1.2 研究基础与相关工作 5

1.3 需求分析与技术难点 5

1.4 研究目标与已实现指标 5

2 作品方案设计及实现 5

2.1 轻量化设想与短窗基线 5

2.2 活动提案与深度排序 6

2.3 全覆盖两级检测与评测修正 6

2.4 双尺度与事件上下文的形成 7

2.5 从误差诊断到表示迁移 7

2.6 时序模型与多模态探索 8

3 作品测试方案及测试结果 9

3.1 测试方案 9

3.2 测试结果及分析 9

3.3 官方反馈与最终交付 10

4 总结 11

4.1 作品展示 11

4.2 局限与展望 12

参考文献 12

1 作品概述

1.1 背景及意义

腕部惯性传感器能够记录送食、持餐具等手部动作，为日常进食时段的自动识别提供基础[1,2]。自由生活条件下，饮水、操作手机及其他重复手部活动可能形成相似信号。算法不仅需要识别局部动作，还需区分持续的进食事件与高分非进食片段。本文聚焦离线事件起止时段检测，不推断食物种类、摄入量或疾病状态。

1.2 研究基础与相关工作

数据来自竞赛提供的智能手表会话及餐次标注。原始TXT含3类时间戳、44个PPG导出列及6个IMU轴。系统显式处理无效时间、包内采样和会话缺口，避免把行号当作统一时间轴。基于腕部运动的已有研究提示，应同时重视自由生活负样本和标注不确定性[1,2]；本作品据此采用候选生成与事件复核分离的结构。

研究阶段另使用KU Leuven FD-I腕部IMU和进食手势标注进行监督预训练；公开的FD-I/FD-II资料合计约513小时，覆盖61人[5]。源域手势可学习及部分目标域候选排序改善，并不直接等于事件检测提升，相关结果单独列为探索性证据。正式提交模型未包含外部预训练编码器。

1.3 需求分析与技术难点

赛题要求兼顾惯用手与非惯用手佩戴，以事件级F1为主指标、起止边界误差为次要指标。本文使用统一IMU模型，不以真实餐次的手侧字段作推理路由；佩戴场景只用于分层分析。针对非惯用手动作弱的情形，另行检验PPG补充信息，但不将未经验证的生理代理加入部署。核心难点为短餐漏检、近似动作误报、跨人泛化以及训练后策略稳定性。

1.4 研究目标与已实现指标

官方反馈最佳事件级F1为0.533333，正确检出56次、误报42次、漏检56次。历史受试者隔离嵌套五折结果为F10.6514，以153个本地可评估事件为分母，属于复现证据。已完成原始TXT到官方三列CSV的Windows程序、源码复现说明和离线可视化交付。

2 作品方案设计及实现

2.1 轻量化设想与短窗基线

研究最初从腕上长期监测出发，希望在识别进食的同时降低持续计算的开销。因此先建立可解释的短窗基线，再设计逐级唤醒的轻量网络，而不是一开始对全天数据运行大模型。基线按5秒窗口、1秒步长切片，提取加速度与角速度的幅值、波动、倾角、频带能量，以及有效率和粗略PPG统计，共37维特征，以LightGBM分类[3]；把连续高分窗合并，去除过短片段并扩展边界，形成餐次事件。

这一阶段打通了原始数据读取、受试者分组、训练和事件评价。早期五折平均F1约0.106，误报多且预测片段破碎。检查还发现，5秒窗与十余分钟餐段之间不能沿用事件IoU定义正窗，否则即使窗完全落在餐内也难以达到正类标准，故改用重叠占窗口时长的比例。统计量能描述短时运动，却

不足以说明它是否属于持续进食；窗口分类与餐次识别之间存在明显距离。该历史分数仅说明当时基线状况，不与后文正式结果直接横比。

随后实现四级级联：活动唤醒层以少量运动特征粗筛，场景层以倾角和姿态变化估计佩戴情形，动作专家用深度可分离卷积处理IMU，生理专家用PPG特征与循环网络补充，最后通过融合网络和两状态隐马尔可夫模型输出事件。初版动作网络仅约3.8万参数，意在把较重的计算留给少量可疑片段。

实际验证中，活动唤醒虽有较高窗口灵敏度，却只能排除少量负窗；场景门控在正样本上的准确率约0.629，难以可靠分流。更重要的是，不同餐次的动作可见性差异很大，一旦前级拒绝，后级网络再强也无法挽回。继续增大CNN、改用残差网络或增强融合，并未稳定解决这个问题。赛题最终要求离线Windows程序，而非手表端实时运行，研究重点遂从端侧省算力转向候选覆盖和事件准确性。

2.2 活动提案与深度排序

为兼顾长时段处理与动作辨别，下一版由秒级活动包络和餐时先验产生候选，再以卷积、时序卷积残差和GRU组成的深度排序模型复核。训练中加入正窗时间抖动、噪声增强、分层负采样，并尝试外部进食数据预训练。部分配置的窗口AUC达到约0.83—0.90，但事件F1仍约0.27：活动连通域的长度和边界使约一半餐段没有满足匹配条件的提案，排序头不能检出从未进入候选池的餐。

早期迁移先尝试较受控的咬食数据，再转向更接近自由生活的FD餐段；两者的局部分类、候选定义与负活动背景并不相同。角速度高频通道、基于运动能量的软路由、冻结部分网络和会话归一化也逐项试过，但没有解决可达提案不足。若只追求窗口AUC，容易把反复出现的动作学得更熟，却依旧漏掉动作稀疏的整餐。由此确认需要先改变检测问题的组织方式，再研究更强的分类模型。

其间发现行号时间轴漂移，以及把窗口行数525误当作525000毫秒的单位错误，导致预测边界异常延长。修复后统一以真实传感器时间戳恢复采样并切开缺口，撤回相关乐观分数及据此提出的“标注误差决定F1上限”论断。这次检查说明，模型判别力之外，候选的时间几何和评价实现同样决定事件检测是否可信。

2.3 全覆盖两级检测与评测修正

针对候选覆盖不足，参考组内平行方案，把“先找活动再分类”改为全时段滑窗评分：用240秒窗、15秒步长提取62维加速度及活动包络特征，以直方图梯度提升模型得到概率序列[4]，再由局部高分窗的密度和支持跨度产生事件，最后用33维概率形态特征复核。第一层允许较多可疑片段，第二层专门控制误报，不再要求一个排序头同时解决召回与精度。初版开发结果约0.41，研究由此转向事件级证据的组织。

此后尝试深度分融合、负样本扩充和多模型平均，曾得到更高的开发数字，但复核发现两处问题：跨折平均中的其他模型训练过当前验证受试者；留一受试者实验也曾复用全数据复核器。仅让窗口分类器按人留出，并不能保证整个系统按人隔离。相关高分被撤回，改为外层五折受试者验证、训练域内交叉拟合；窗口模型、复核器和阈值选择都必须排除对应验证人。此后比较不再把旧分数视为有效的提升阶梯。

2.4 双尺度与事件上下文的形成

长窗虽然保留了持续行为背景，却会稀释短餐和微弱动作。组内15秒ACC+GYRO方案提供了启发：保留宏观分支，同时加入15秒窗、7.5秒步长的微观分支，以重力对齐及角速度特征描述局部运动。微分支采用47维特征与LightGBM，宏分支另加入1维时间先验，共63维。两路候选取并集，使系统既能观察数分钟的持续性，也能保留短时手腕转动，不必依赖一个固定尺度。

微窗带来更多候选，也放大了日常手部活动的误报。为此加入同会话非极大值抑制、受试者级准入控制，以及逻辑回归与受限LightGBM的概率融合。前者提供较平滑的线性判断，后者补充非线性关系；候选数量、分数和事件阈值均在训练域内选择。这一完整配置达到开发F1约0.559，但仍难区分“持续进食”与“局部很像进食”的活动。

剩余错误促使复核从候选内部扩展到前后背景。Context-v1在同一会话内观察候选前后各20分钟的宏微概率流，描述平均强度、越固定阈值比例、覆盖率、相邻连续段及证据集中程度。其直观依据是：相同的高分峰，若出现在长时间持续手部活动中，与从低活动背景中形成的集中餐段，含义可能不同。缺失背景保留为缺失并单独记录覆盖率，不把未采到的数据误作低活动，也不借用其他会话或真实餐次位置。

新增60维上下文与56维基础事件特征组成116维表示。相较上一发布配置，严格嵌套五折聚合F1由0.5590升至0.6514，形成当时开发基线。该变化是完整配置的配对结果，不等于每一项上下文特征都具有独立收益。最终流程为真实时间轴解析、双尺度评分与候选并集、116维融合复核、候选控制和事件解码；训练评估与提交程序共用实现。选择树模型作为正式方案，依据是其事件结果与交付稳定性，而非预先排除深度学习。

2.5 从误差诊断到表示迁移

达到0.65后，研究不再只看总分，而是追踪39个漏检和83个误报分别发生在哪一环。最初怀疑候选上限过严，因为11个短餐在候选控制后失去匹配机会。但冻结模型分数、只取消单项操作的诊断显示：取消受试者上限仅多检出1餐，却增加21个最终误报；逐餐恢复最有利候选时，11餐中仍有10餐无法通过原事件阈值。问题遂从“候选有没有”转为“已有真候选为什么得分低”，而不是继续放宽上限。

对31个原始候选可达的漏检进一步追踪，25个最优候选的融合分数低于阈值超过0.10，15个出现明显的逻辑回归与LightGBM分歧。原先担忧Context-v1过度压制短餐，但按预定的严格定义没有发现明确样本，不能据此删除上下文。增加上下文形态、强化困难负例权重、学习自适应融合，也未形成稳定的事件净收益。上述诊断只解释冻结模型，不把使用真实标签的反事实当作新成绩。

这些看似合理的修改还暴露了优化目标间的矛盾。扩展上下文后，内层聚合F1仅由0.76560变为0.76567，少报13个误报的同时也丢掉8个正确事件，实际近乎持平；困难负例加权虽增加正确检出，却带来更多误报。两种复核器存在分歧，也不意味着学习一个更复杂的融合器就能改善结果。这些对照促使后续不再反复重组已有统计量，而去寻找当前表示尚未保留的信息。此处内层统计包含重复训练域，不视作新增独立餐次。

随后回到原始信号，比较5、10、15、30和60秒的运动尺度。5秒角速度方差在各折显示一致的真伪差异，促成六项短尺度特征的对照；然而完整内层实验只净增2个正确事件，同时增加4个误报。

回查新旧事件发现，简单运动强度并不能稳定区分被救回的餐与新增误报。于是研究重点从“运动有多强”转为“短动作怎样在时间上组织”。

第一轮时序表示和从零训练的编码器没有稳定优于随机表示。训练损失很低，而未见受试者上的错误置信度偏高，提示有限餐次反复抽样容易过拟合。为区分表示与读出层的作用，改用冻结编码器、固定分段池化和正则化线性读出；在各训练分区内用无负样本的VICReg学习增强一致性，避免把相邻同类动作强行当成负例。三折候选AP为0.2959，仍低于同架构随机表示的0.3978。这否定了该自监督配置，却不能说明原始IMU没有信息。

因此转向更贴近任务的外部手势监督。KU Leuven FD-I提供腕部IMU和进食手势标注[5]，但其物理量与竞赛原始ADC的换算无法核实，直接搬用幅值并不可靠。新方案对每个5秒片段的ACC、GYRO三轴组去均值并按RMS缩放，保留相对运动形态，训练小型动作编码器。源域27人训练、7人验证的AP为0.8440；冻结后用于目标候选，在24名开发受试者的三折比较中，AP由随机表示的0.3803升至0.5405，三折均改善，说明外部手势信息具有迁移价值。

但有信息不等于有事件增益。把新评分与原复核概率固定平均，事件F1仅由同范围基线0.7213变为0.7222；无效运动输入改为中性回退虽多检出8餐，却新增14个误报，仍近乎持平；把少量冻结表示联合送入复核器也未改善。评分尺度、缺失处理和策略选择会共同改变最终事件，候选AP不能替代这一检验。这里的24人、97餐属于训练侧开发子集，结果不与正式五折0.6514直接比较。

2.6 时序模型与多模态探索

冻结表示的局限促成源域手势与目标事件的联合适配，并以固定编码器作对照。训练侧检查发现，最初小批量适配甚至使固定训练集损失恶化；确认梯度能够回传后，分别检验取消裁剪和扩大批量，后者改善了训练目标。完整事件对照也由基线0.7213升至0.7374，但仍低于冻结FD表示的0.7419，且部分低分受试者未受益。优化修复不能直接视为跨人泛化改善。进一步扩大局部感受野、使用手势概率形态，以及桥接通用预训练编码器，都未得到足够的配对收益。

对时序信息也做了反证检查：同一冻结表示分别保留顺序或打乱有效片段，小型时序读出没有稳定超过分段线性池化；把动作编码器从约1.2万扩大至12.7万参数、让感受野覆盖完整5秒，源域AP近乎不变而概率误差更大。通用预训练模型在当前无量纲输入桥接下还弱于同架构随机权重，说明设备和预处理适配不能被“预训练”一词替代。这些结果限定具体配置，而不是证明时间关系或更大模型无用。

之后将注意力转向候选内外的连续关系，而非只汇总片段统计。冻结FD动作编码器每5秒产生16维表示，分别保留候选内部及前后各10分钟序列；缺口不拼接，以真实相对时间编码位置。对相同输入比较简单池化、TCN与两层小型Transformer[6]，并与原复核分数固定融合。在24人、97餐开发对照中，基线F1为0.7213，池化为0.7396，TCN为0.7638，Transformer为0.7604。时序读出有局部正面证据，但注意力并未优于卷积。

为检验能否推广，冻结方案后在另一7名历史竞赛受试者的33餐上验证：基线为0.7458，TCN回落到0.6897，Transformer为0.7241。检查同一批输入发现，最终重拟合模型对正负候选都更保守，真候选平均运动分数约0.26，明显低于旧折模型；重算分数与封存结果一致，未发现缓存或推理重构失

配。训练规模、受试者组成和随机性同时变化，尚不能指定唯一原因。随后在合法训练分区内做三种子平均，也没有超过相应单模型。因此局部0.76不能作为正式0.70成果。

佩戴侧分析进一步表明，新增时序模型在7人验证中的净漏检集中于非惯用手场景。这促使重新检查PPG能否补足弱动作，而不是认定非惯用手完全无法用IMU识别。下载说明与组内解析代码提供线索，逐包检查发现：约602毫秒一个PPG时间戳，完整包含15行不同向量，与每列约25Hz序列相符；旧“约2Hz”解释混淆了包率与波形率。PPG3、PPG5被作为两路候选光学信号独立处理，但光路映射和时间锚点仍未得到厂家确认。

在连续性、缺口和运动污染审计后，提取候选前、中、后阶段的双路谱峰与相对幅度差，并设置仅质量信息的对照，以区分生理增量和采集条件。794个开发候选中，仅340个至少具有一项有效差值。专项复核直接替换原分数使F1降至0.6842；继而保留原IMU概率和事件策略，只学习低维正则化残差，F1为0.7126，减少5个误报但丢失4个正确事件。现有代理特征尚未给出事件净收益，不能因此否定所有PPG方法，也不能将谱峰直接称为可靠心率或HRV。

最后检验两个较窄的解释：用外部动作头在候选相关会话的完整有效时间轴上补提案，1317个新候选仅使可达餐次由93/97增至94/97，且1235个与任何真餐无重叠；按受试者和真实事件均衡复核损失，F1由0.7213变为0.7204，短餐略有增加但误报也上升。研究因而保留双尺度与Context-v1正式版本，把后续关注点转向近似进食动作的辨别和跨人稳定性，而非继续堆叠阈值与候选。

3 作品测试方案及测试结果

3.1 测试方案

采用受试者互斥的外层五折验证，模型训练及策略选择均在各自训练域内完成。事件按一对一IoU匹配，F1=2TP/(预测数+真实事件数)。赛题要求IoU>0.25[7]；历史评估器采用≥0.25，但冻结的114个正确匹配最小IoU为0.2604783，无等号边界命中，该组预测计数不受差异影响。

本地153个可评估餐次须位于会话内，有效窗口覆盖跨度不少于餐长50%，且单窗最大重叠至少120秒。该分母描述本地数据条件，不替代官方测试分母。开发数据经过反复研究，嵌套结果仍不等于未接触测试集上的泛化证明。

3.2 测试结果及分析

表1 历史本地基线的受试者互斥嵌套五折结果

外层折号	TP / 可评估事件 / 预测事件	F1
0	16 / 23 / 35	0.5517
1	30 / 31 / 46	0.7792
2	15 / 27 / 33	0.5000
3	25 / 32 / 42	0.6757
4	28 / 40 / 41	0.6914
聚合	114 / 153 / 197	0.6514

聚合灵敏度为0.7451，阳性预测率为0.5787，误报83个、漏检39个。114个正确匹配事件的起始与终止边界MAE分别为323.43秒和116.87秒；该统计仅针对已匹配事件，不能表示所有餐次的定位误差。

表2 历史本地基线的佩戴场景与餐次时长召回率

真实事件分层	正确检出 / 可评估事件	召回率
惯用手佩戴	52 / 63	0.8254
非惯用手佩戴	62 / 90	0.6889
短餐（<10分钟）	20 / 39	0.5128
中等餐（10至不足20分钟）	62 / 74	0.8378
长餐（≥20分钟）	32 / 40	0.8000

短餐和非惯用手场景仍较弱。误报无法可靠归属餐次佩戴侧或时长，因此表2不报告切片PPV与F1；两类场景也非受控配对，差异不能全部归因于佩戴侧。主要方法特点是用双尺度候选保留互补证据，并以同会话上下文判断事件，而非仅凭某个高分窗口决策。工程检查另覆盖原始读取、训练与推理一致性、官方输出格式和独立打包运行。

3.3 官方反馈与最终交付

官方按完整有效真实事件统计，采用事件一对一匹配且IoU严格大于0.25。三次反馈均记录112个有效真实事件（表3），未独立核验各次评测人群是否一致，不能据此推断统计显著性。官方与历史本地结果的分母及评价范围不同，历史0.6514仅作复现证据。

表3 三次官方测试反馈（有效真实事件均为112）

反馈	TP	FP	FN	灵敏度	阳性预测率	F1
第一次	42	26	70	0.375000	0.617647	0.466667
第二次	49	27	63	0.437500	0.644737	0.521277
第三次	56	42	56	0.500000	0.571429	0.533333

排查发现，部署宏窗训练正样本比例仅3.18%，而交叉验证约31%至35%。统一采样重训后，宏窗和微窗分别为33.05%和31.32%；复核器也改用受试者隔离的OOF特征。多项变化共同发生，不能将改善唯一归因于某一项。最后一次试测保持模型不变，将事件阈值由0.659527降至0.458266，比第二次多检出7餐、增加15个误报，反映召回与精度的权衡。

后续本地探索以T24基线F1 0.593103为参照：候选上限增至8后为0.574132（TP增加5、FP增加22）；融合对照为0.572491（TP减少9、FP减少12）。两项均未生成EXE；半步尝试在运行前停止，无结果。这些是本地探索，不是官方成绩。

最终选择官方反馈最佳的第三版，F1为0.533333。部署版本为official_deployment_f1_policy_v3，事件阈值0.4582664763345077、融合权重0.25、受试者候选上限6；宏窗、微窗及复核表示分别为63、47、116维。提交程序位于submission/EatingDetection.exe，完整源码与推理、复现说明位于dist/submission。

4 总结

4.1 作品展示

交付Windows可执行程序及完整模型源码、权重、训练评估与复现说明。模型和运行依赖均已内置，无需预装Python、CUDA或联网；启动时将内置库释放至系统临时目录。无参数运行EatingDetection.exe，读取同级ACC_test_data并生成results.csv，包含externalid、beforeTime、afterTime三列，时间为Unix毫秒。

运行start.bat可启动离线可视化，上传数据并查看同一正式模型的预测；服务仅监听本机地址，浏览器不另行实现模型判断。Monitor页联动显示运动、宏窗、微窗和事件轨迹，便于回看误报或漏检片段（图1）。

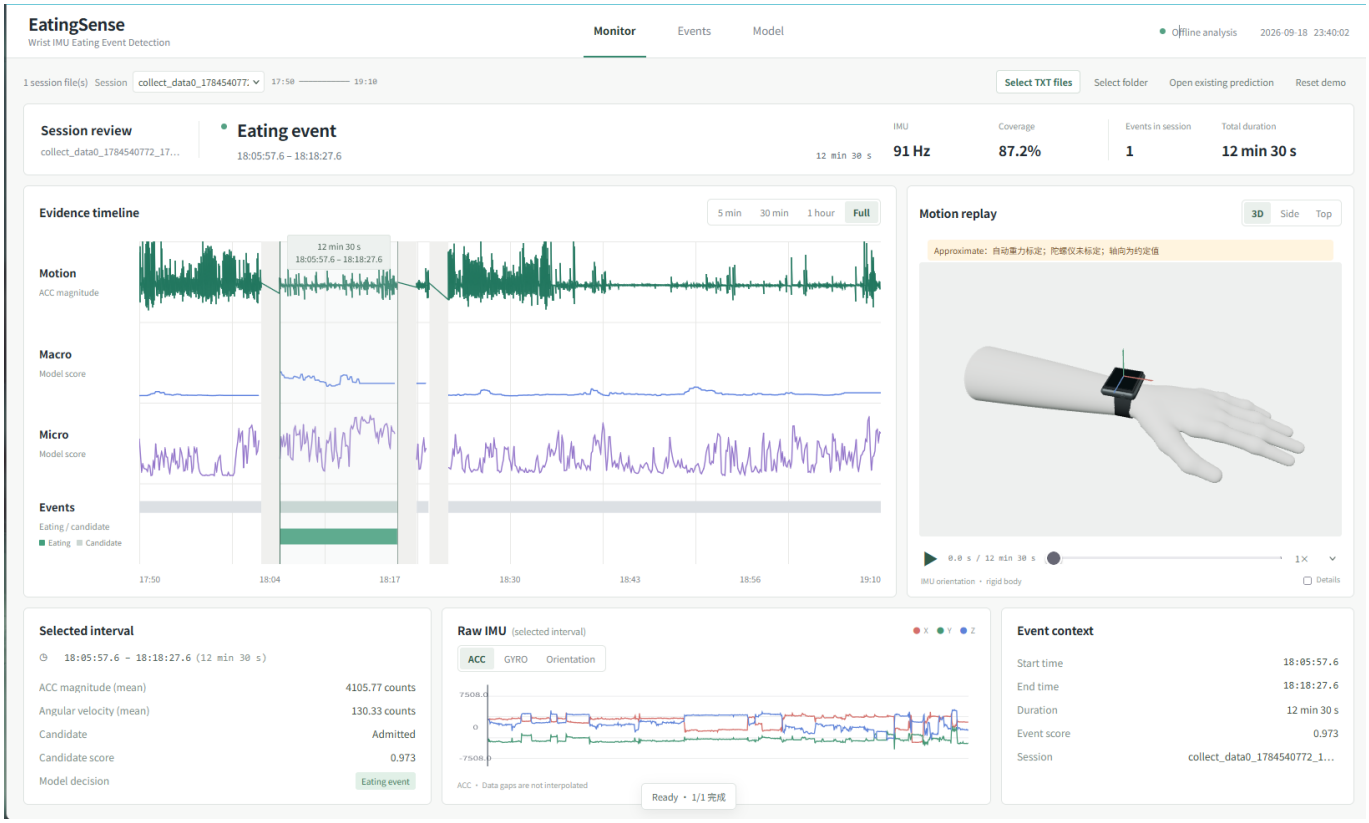


图1 Monitor页：证据时间轴、原始IMU与腕部姿态回放

Events页汇总检出事件并定位到对应区间（图2），Model页展示模型信息。姿态回放用于辅助理解运动，在缺少标定时仅作近似展示，不解释为绝对位移或医学指标。

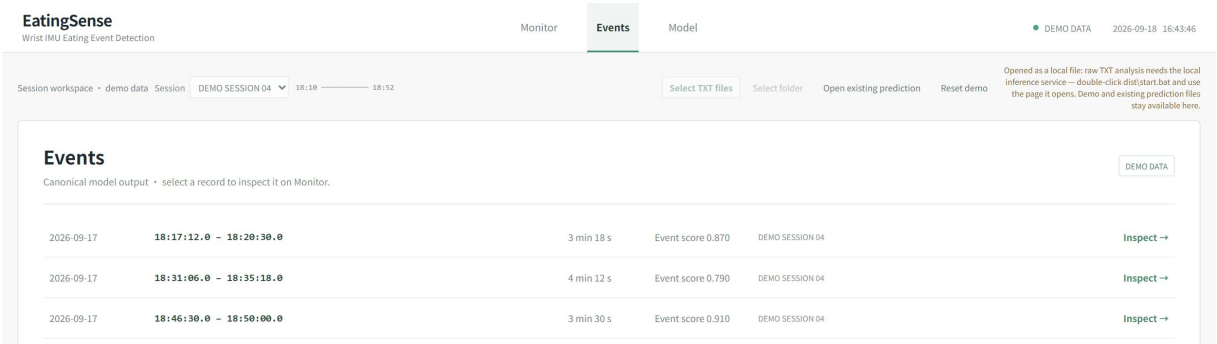


图2 Events页：事件列表与定位功能（合成演示数据）

4.2 局限与展望

本研究逐渐分清了“动作可辨”“候选可达”和“事件检出”三个问题。全覆盖滑窗解决了早期提案遗漏的部分困难，短窗补充了局部动作，上下文又帮助抑制误报；但这些证据仍不能稳定地区分真实进食与相似的日常活动。短餐的有效动作较少、边界更易受停顿影响，非惯用手的运动线索也更弱，尚有相当一部分餐次未被识别。

时序模型曾在开发子集取得明显改善，却没有在后续人群中复现，说明目前更缺少稳定利用信息的能力，而非单纯缺少网络参数。后续值得围绕饮水、做饭等近似动作扩大有明确标注的对照，保留送食片段的节律和前后关系，并研究不同佩戴方式下可迁移的表示。外部数据已显示局部价值，但设备量程、坐标系和生活场景差异仍需认真处理；PPG也值得继续探索，不过首先需要明确字段含义、提高有效覆盖，并验证它确实补充了动作信息。

另一方面，通过IoU匹配不代表起止时刻足够精确，当前起始边界误差尤其值得改进。将来的评价应同时关心能否发现短餐、误报是否影响全天使用，以及边界是否便于回顾。现有数据人数有限，餐次标注和采集缺口带来不确定性，反复开发还会削弱交叉验证的独立性。因此0.70仍是尚未实现的目标；现有三次官方反馈之外，跨人和新数据泛化仍待验证。可视化系统为逐段检查提供了工具，也为后续结合更准确的行为标注、改进模型与实际使用体验留下了基础。

参考文献

[1] Stankoski S, Jordan M, Gjoreski H, Luštrek M. Smartwatch-Based Eating Detection: Data Selection for Machine Learning from Imbalanced Data with Imperfect Labels[J]. Sensors, 2021, 21(5): 1902.

[2] Heydarian H, Adam M, Burrows T, et al. Assessing Eating Behaviour Using Upper Limb Mounted Motion Sensors: A Systematic Review[J]. Nutrients, 2019, 11(5): 1168.

[3] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[C]//Advances in Neural Information Processing Systems 30. 2017: 3146-3154.

[4] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

[5] Wang C, Kumar T S, De Raedt W, et al. Replication Data for: Eating Speed Measurement Using Wrist-Worn IMU Sensors Towards Free-Living Environments[DB/OL]. KU Leuven RDR, 2024. DOI: 10.48804/CN8VBB.

[6] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems 30.2017: 5998-6008.

[7] 第十一届全国大学生生物医学工程创新设计竞赛组委会. 基于智能手表传感器的进食检测算法赛题说明及测试接口[S]. 2026.